Számítógépes szemantika

Berend Gábor

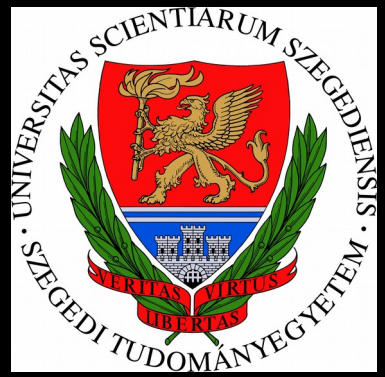

Értékelés

- Részteljesítések
  - Órai részvétel (és aktivitás): 25%
  - Szakirodalomfeldolgozás (és előadás): 35%
  - Projektmunka: 40%

Értékelés

- Részteljesítések
  - Órai részvétel (és aktivitás): 25%
  - Szakirodalomfeldolgozás (és előadás): 35%
  - Projektmunka: 40%
- Végső jegy: részteljesítések súlyozott átlaga egészre kerekítve
  - **Pl. Ó:4, Sz:5, P:4 → 0,25*4+0,35*5+0,4*4=4,35 → 4**

Lehetséges projektmunkák

- Megegyező tartalmú kérdések felismerése
  - https://www.kaggle.com/c/quora-question-pairs
- Etikusság
  - https://blog.conceptnet.io/2017/04/24/conceptnet-numberbatch-17-04-better-less-stereotyped-word-vectors/
- Fedőnevek ágens
  - https://jamesmullenbach.github.io/2018/01/02/codenames-fun.html
- Saját témák

Mikről lesz szó a tárgyon?

- Szavak jelentését megragadni (közelíteni) képes számítógépes reprezentációk létrehozása
- Mire használhatók ezek a reprezentációk?
- Hogyan értékelhetők ki ezek a reprezentációk?
- Többnyelvű reprezentációk?
- Python + matek (valószínűség és lineáris algebra)
  - Numpy, scipy, sklearn csomagok

Python használata

- Python 2 vs. **Python 3**
  - https://docs.python.org/3/tutorial/
- Virtualenv vs. **anaconda**
  - https://www.continuum.io/downloads
- Nem csak Python
  - pip, ipython, jupyter, ...

Python alapok

- OO nyelv, dinamikus típusokkal
  - `type(valtozonev)` utasítással megtudhatjuk a változó aktuális típusát
- Nem muszáj ;-vel zárni a sorokat
- Cserébe az indentálásra ügyelni kell (szóközök)
- Asszociatív tömbök használatának támogatása

Python alapok – Fontos tárolók

- `tuple`
  - `t = (“Sanyi”, 22, “körte”)`
  - Tipikusan eltérő “szemantikájú” adatokat csomagolunk össze segítségével
  - Inmutable (`t[1]=23` hibát eredményezne)
- `list`
  - `l = [5,3,1,4]`
  - Tipikusan azonos típusú adatok összefűzésére használjuk
  - Mutable (`l[1]=4` nem okoz hibát)

Python alapok – Fontos tárolók

- `dict`
  - `d = {“Sanyi”:22, “Manyi”:33, “Enci”:52}`
  - Asszociatív tömböt (kulcs-érték párok) valósít meg
  - `KeyError`, ha nem létező kulcsra hivatkozunk (pl. `d[‘Éva’]`)
- `set`
  - Halmazt valósít meg (tulajdonképp egy olyan dict, ami nem rendel értékeket a kucsokhoz)
- Továbbiak: `defaultdict`, `Counter`, ...
  - A `collections` csomagból importálhatjuk be őket

Python vezérlési szerkezetek

- Ismétléses vezérlés

```
for valtozo in range(20):
  utasitasok
```

- Feltételes vezérlés (&& → and, || → or)

```
if feltetel:
  utasitas(ok)
elif feltetel:
  utasitas(ok)
else:
  utasitas(ok)
```

Python I/O

- Plain text fájlbeolvasás

```
for line in open('be.txt', 'r',
encoding='utf-8'):
    print(line)
```

- Plain text kiíratás

```
f = open('workfile', 'w')
f.write('Dummy content...')
f.close()
```

- Alternatív megoldás (with statement használatával)

```
with open("x.txt") as f:
```

Python függvények

```
def fuggveny_nev(parameterek):
    fuggvenytorzs
    [return valtozo(k)]
```

- Például

```
def hello_bello(hello)
  if hello:
     print('Hello')
  else:
    print('Bello')
```

Importálás lehetőségei

- Külső modulok funkcionalitásának használatához

```
import modulnev
import modulnev as alias
from modulnev import metodus
```

- A külső modulnak persze már telepítve kell legyen
  - `pip install[ --upgrade] modulnev`

Numpy vs. Matlab

- Sok hasonlóság mellett fontos különbségek is

	Numpy	Matlab
Transzponálás	Y=X.T	Y=X’
Mátrixszorzás	C=A.dot(B)	C=A*B
Elemenkénti szorzás	D=A*B	D=A.*B

  - Mátrixszorzás esetén $A \in \mathbb{R}^{kxl}, B \in \mathbb{R}^{lxm}$
  - Elemenkénti szorzás esetében $A \in \mathbb{R}^{kxl}, B \in \mathbb{R}^{kxl}$

Gyakorlás

- Írjunk egy függvényt, ami kiszámolja az n-edik Fibonacci számot
- Hozzunk létre egy listát, ami a Fibonacci sor első 20 elemét tartalmazza
- Érjük el, hogy az előző lista kétszer egymás után legyen fűzve
- Az előző lista minden elemét emeljük négyzetre
  - List comprehension

Szemantika (jelentéstan)

- Disztribúciós hipotézis
  - Hasonló jelentésű szavak környezetében hasonló szavak találhatók
- Az elmélet >50 éves, az első számítógépes megvalósítás is már >20
  - Igazán népszerű csak az elmúlt években lett

Folytonos reprezentáció

alma [1 0 0 0 … 0 0 0 0 0 … 0] → [3,2 -1,5]

…

körte [0 0 0 0 … 1 0 0 0 0 … 0] → [2,8 -1,6]

…

lapát [0 0 0 0 … 0 0 1 0 0 … 0] → [-4,1 12,6]

…

zebra [0 0 0 0 … 0 0 0 0 0 … 1] → [3,8 0,5]

Versengő paradigmák

- 2013: word2vec megjelenése
  - Korábbi években is voltak már NN-alapú modellek

Versengő paradigmák

- 2013: word2vec megjelenése
  - Korábbi években is voltak már NN-alapú modellek

***Don't count, predict!* A systematic comparison of context-counting vs. context-predicting semantic vectors**

Marco Baroni and **Georgiana Dinu** and **Germán Kruszewski**

Versengő paradigmák

- 2013: word2vec megjelenése
  - Korábbi években is voltak már NN-alapú modellek

***Don't count, predict!* A systematic comparison of context-counting vs. context-predicting semantic vectors**

Marco Baroni and **Georgiana Dinu** and **Germán Kruszewski**

Rehabilitation of Count-based Models for Word Vector Representations

---

Rémi Lebret[1,2] and **Ronan Collobert**[1]

word2vec sematikusan

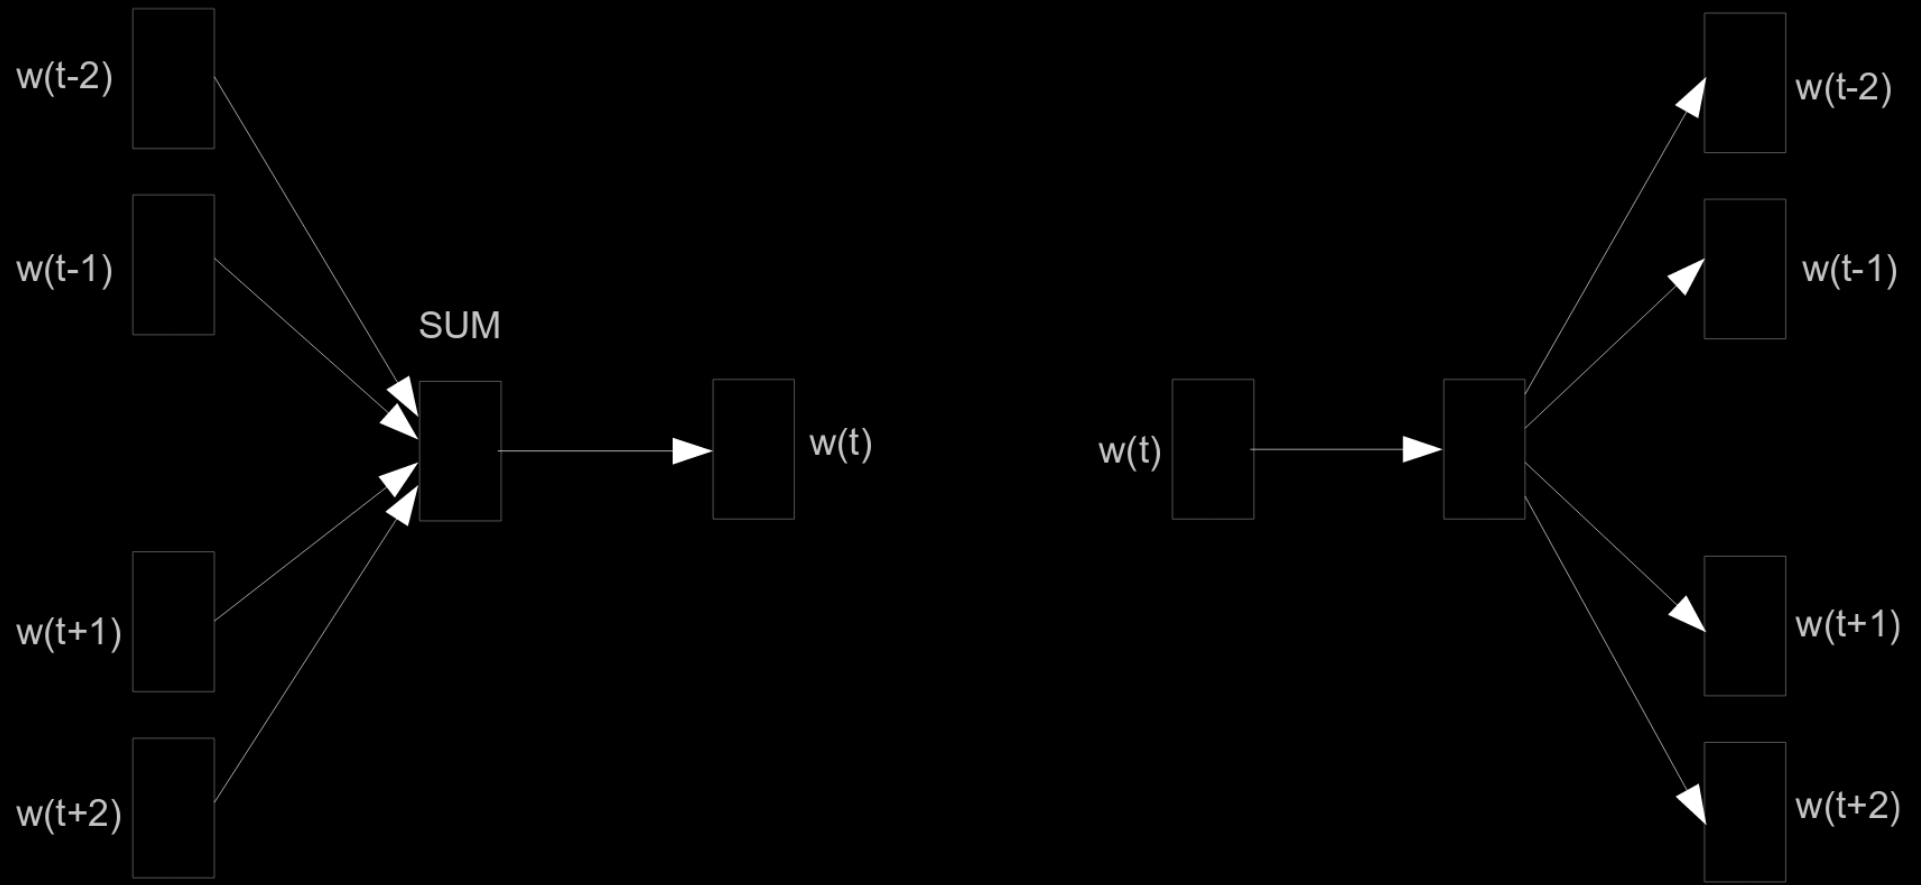

CBOW **Skip-gram**

word2vec neurális hálós értelmezése

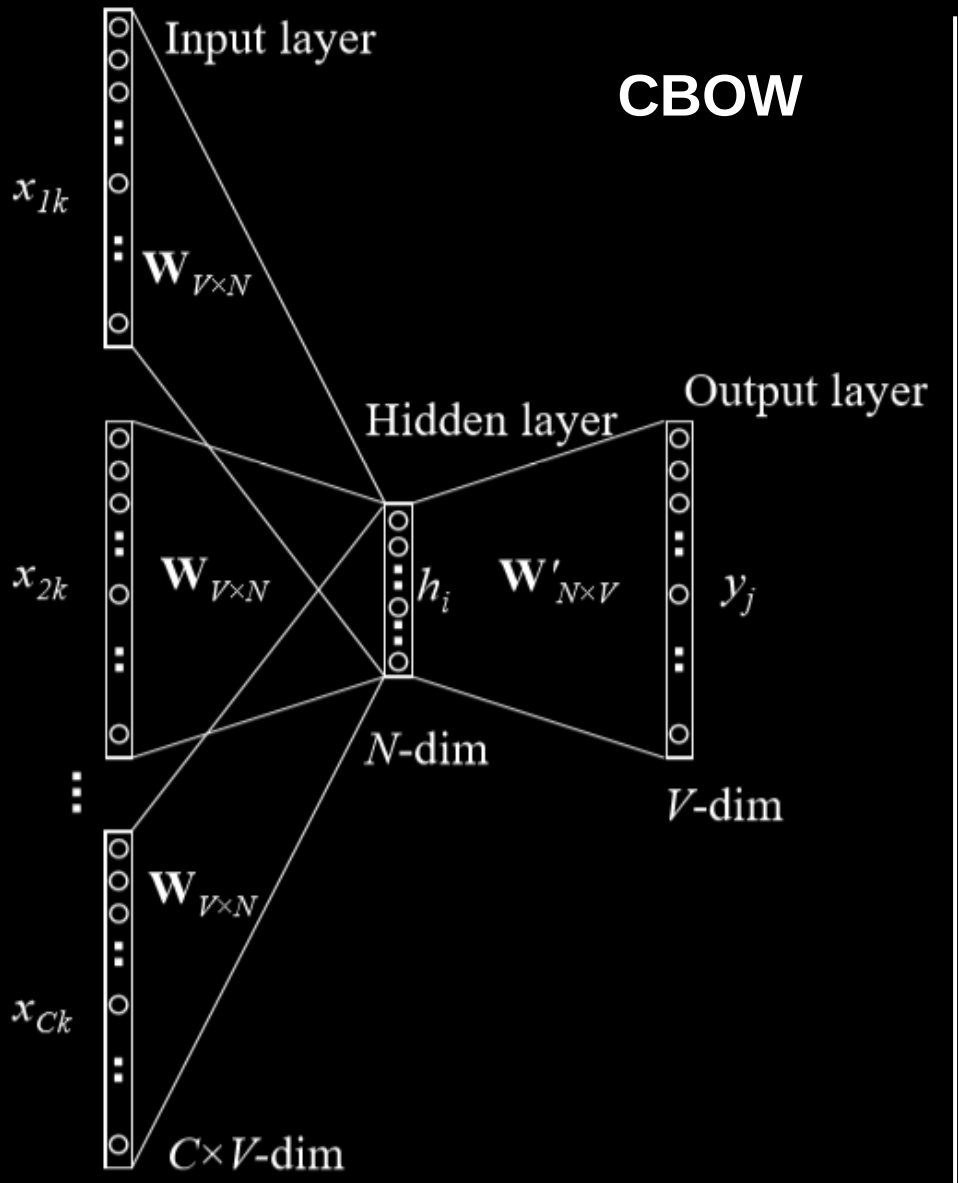

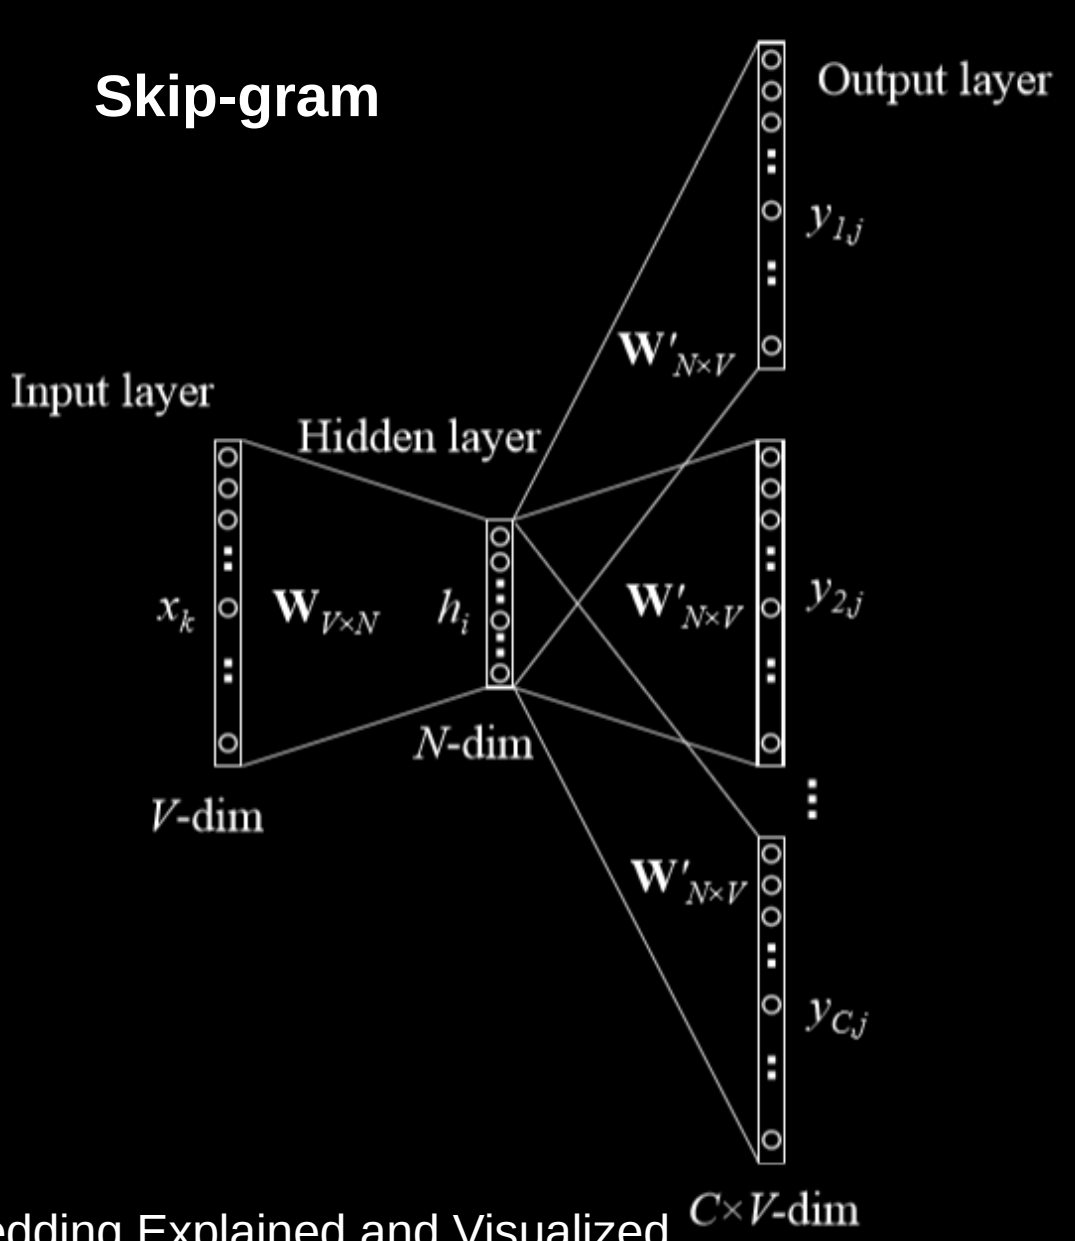

Ábrák forrása: Xin Rong: Word Embedding Explained and Visualized

word2vec célja

- Hasonló jelentésű input szavak hasonló outputot eredményezzenek

$$y(x) = softmax(W'(W 1_x))$$

  - a és b szó jelentése minél hasonlóbb, y(a) és y(b) (eloszlás)vektorok annál inkább hasonlítani fognak
  - CBOW: x “környező” szavak reprezentációi alapján akarjuk a “középső” szót előrejelezni y(x)-szel
  - Skipgram: x “középső” szó reprezentációja alapján akarjuk a “környező” szavakat előrejelezni y(x)-szel

Szóanalógiák

- a:b::c:?

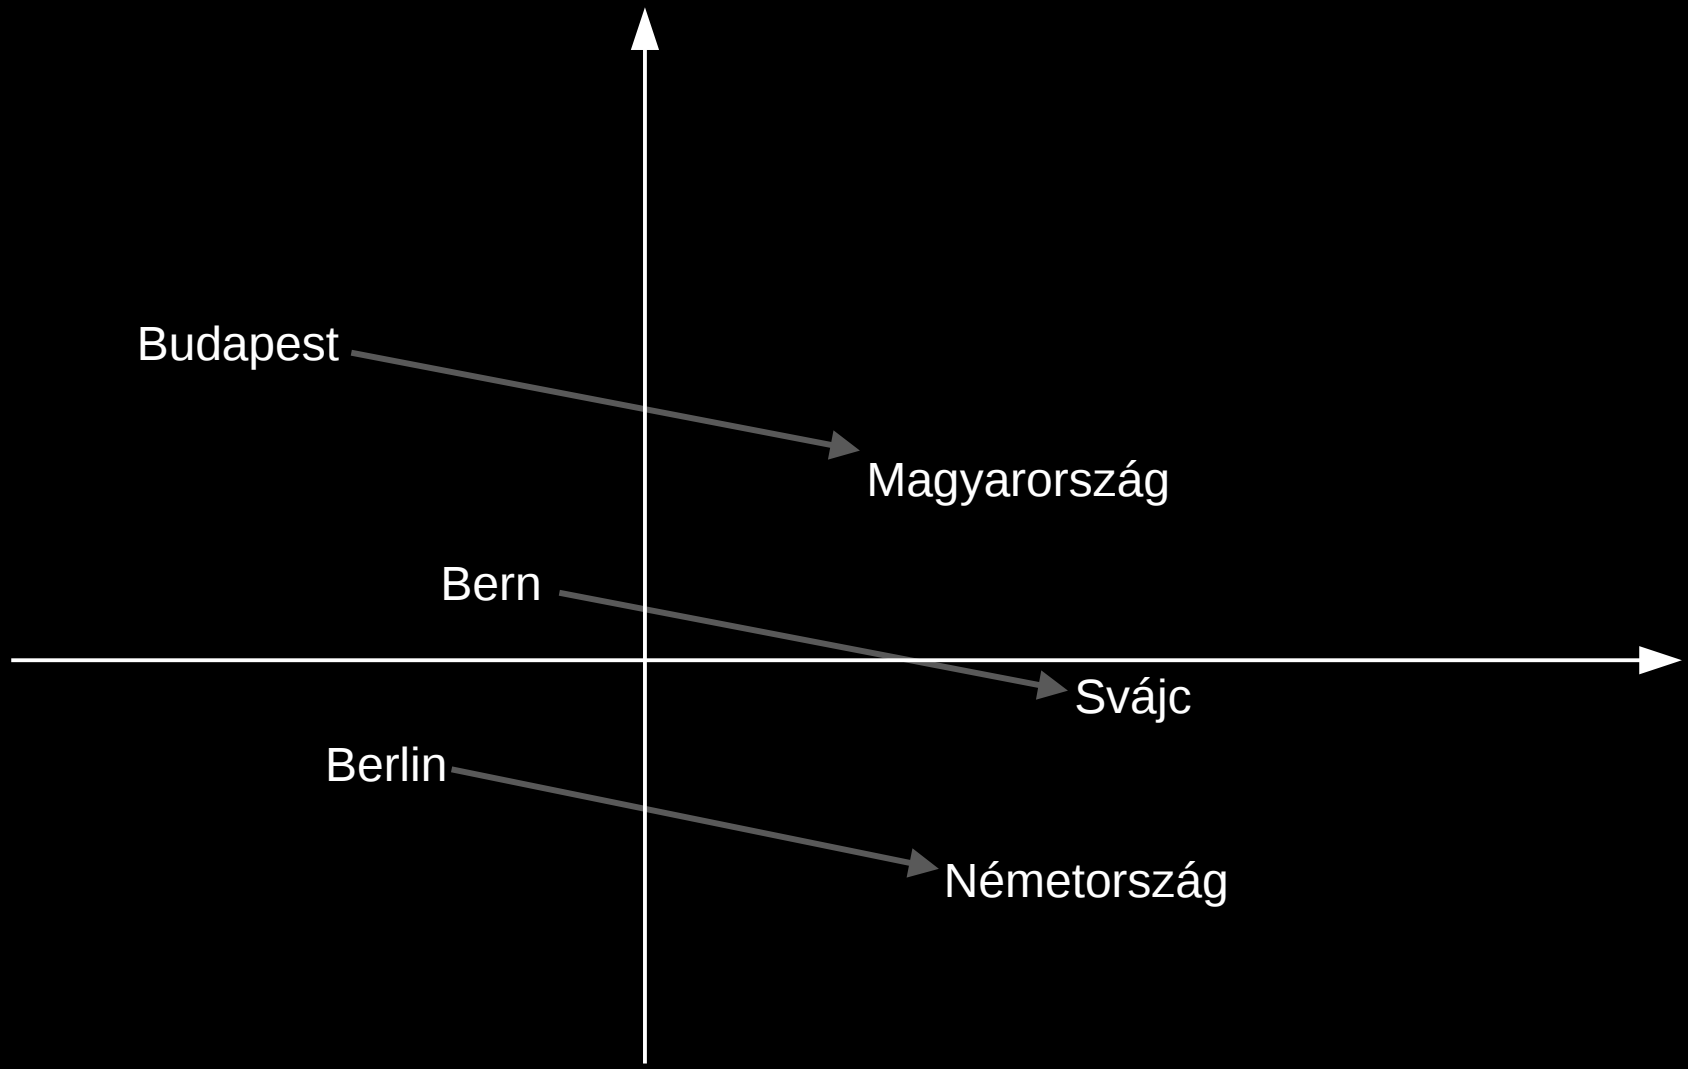

RepEval 2016

Analysis Track

- **Problems With Evaluation of Word Embeddings Using Word Similarity Tasks** [pdf]
  Manaal Faruqui, Yulia Tsvetkov, Pushpendre Rastogi, Chris Dyer

- **Intrinsic Evaluations of Word Embeddings: What Can We Do Better?** [pdf]
  Anna Gladkova, Aleksandr Drozd

- **Issues in Evaluating Semantic Spaces Using Word Analogies** [pdf]
  Tal Linzen

- **Intrinsic Evaluation of Word Vectors Fails to Predict Extrinsic Performance** [pdf]
  Billy Chiu, Anna Korhonen, Sampo Pyysalo

- **A Critique of Word Similarity as a Method for Evaluating Distributional Semantic Models** [pdf]
  Miroslav Batchkarov, Thomas Kober, Jeremy Reffin, Julie Weeds, David Weir

Folytonos reprezentáció

alma [1 0 0 0 … 0 0 0 0 0 … 0] → [3,2 -1,5]

…

körte [0 0 0 0 … 1 0 0 0 0 … 0] → [2,8 -1,6]

…

lapát [0 0 0 0 … 0 0 1 0 0 … 0] → [-4,1 12,6]

…

zebra [0 0 0 0 … 0 0 0 0 0 … 1] → [3,8 0,5]

Ritka folytonos reprezentáció

alma [3,2 -1,5] → [0 1,7 0 0 -0,2 0]

...

körte [2,8 -1,6] → [0 1,1 0 0 -0,4 0]

...

lapát [-4,1 12,6] → [1,7 0 -2,1 0 0 -0,8]

...

zebra [3,8 0,5] → [0 0 1,3 0 -1,2 0]

Szófaji kódolás eredményei

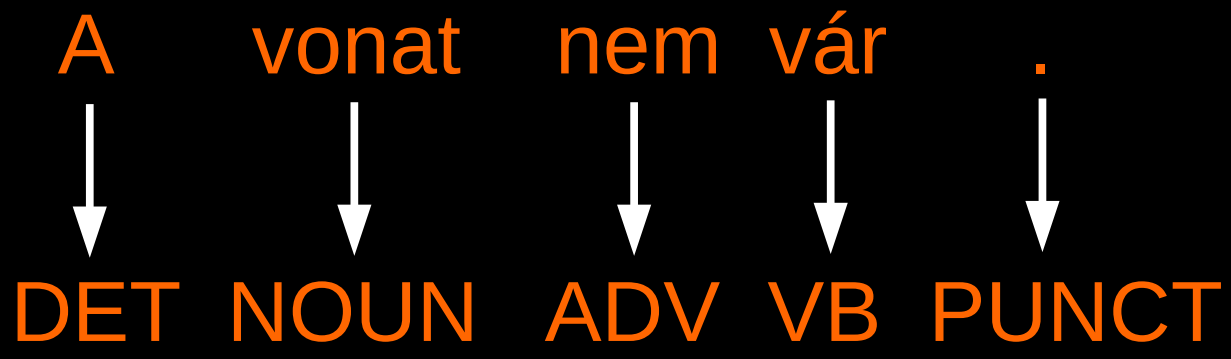

- Folytonos reprezentáció

	bg	da	de	en	es	hu	it	nl	pt	sl	sv	tr	Avg.
polyglot	92.11	93.03	93.10	94.80	94.64	89.23	92.90	90.07	94.36	89.36	89.14	81.33	91.17
CBOW	90.19	90.36	88.46	91.22	91.55	86.07	87.11	88.09	92.45	87.82	87.00	79.30	88.30
SG	88.10	88.84	86.48	90.19	91.34	84.38	85.09	85.11	91.77	88.17	84.48	78.72	86.89
Glove	83.10	81.95	83.07	86.64	84.65	77.34	79.98	78.54	86.62	80.91	78.77	76.77	81.53

Szófaji kódolás eredményei

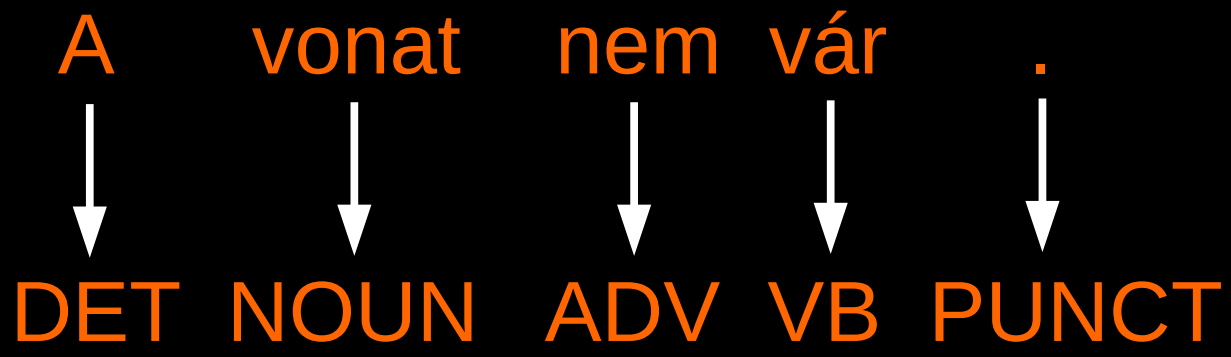

- Folytonos reprezentáció

	bg	da	de	en	es	hu	it	nl	pt	sl	sv	tr	Avg.
polyglot	92.11	93.03	93.10	94.80	94.64	89.23	92.90	90.07	94.36	89.36	89.14	81.33	91.17
CBOW	90.19	90.36	88.46	91.22	91.55	86.07	87.11	88.09	92.45	87.82	87.00	79.30	88.30
SG	88.10	88.84	86.48	90.19	91.34	84.38	85.09	85.11	91.77	88.17	84.48	78.72	86.89
Glove	83.10	81.95	83.07	86.64	84.65	77.34	79.98	78.54	86.62	80.91	78.77	76.77	81.53

- Ritka folytonos reprezentáció

	bg	da	de	en	es	hu	it	nl	pt	sl	sv	tr	Avg.
polyglot$_{SC}$	96.04	95.71	96.33	97.20	96.14	92.92	95.21	93.43	95.96	94.10	94.36	85.93	94.44
CBOW$_{SC}$	95.10	95.35	95.61	97.08	95.75	92.17	94.51	92.61	95.42	92.96	93.18	85.12	93.74
SG$_{SC}$	94.67	95.49	95.47	96.91	95.29	91.97	94.11	93.12	95.28	92.63	93.60	84.99	93.63
Glove$_{SC}$	93.16	93.63	94.61	96.10	93.36	88.62	92.88	90.16	94.65	90.31	92.19	83.36	91.92

Szófaji kódolás eredményei

A vonat nem vár .

DET NOUN ADV VB PUNCT

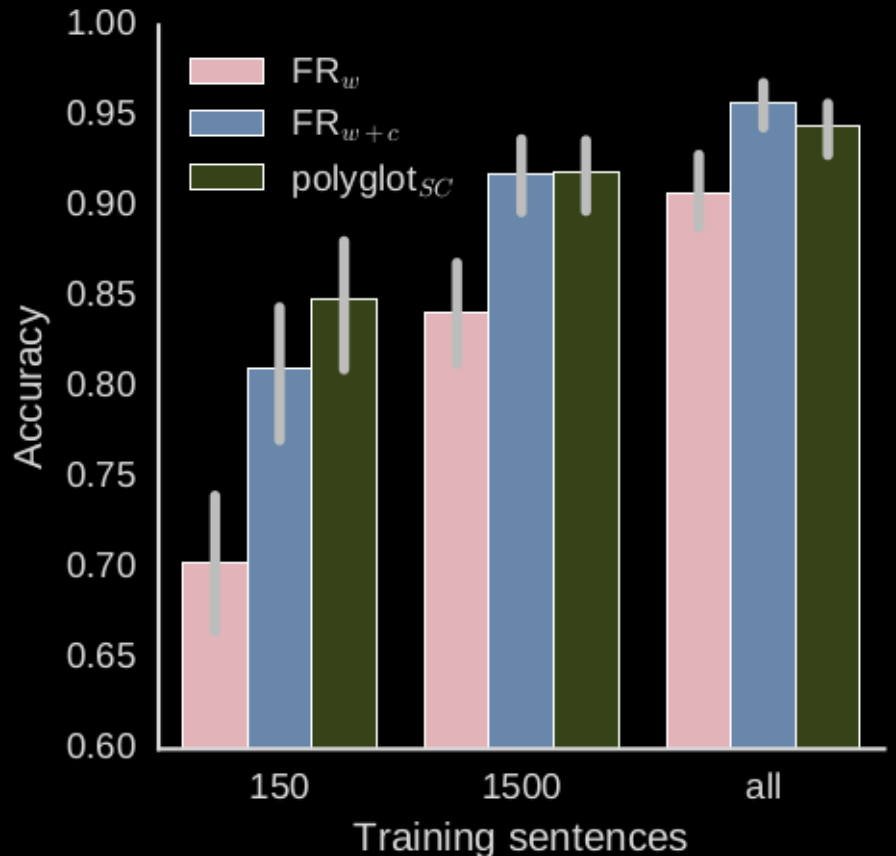

Mondatszintű reprezentációk

- Skip-thought vektorok
  - Rekurrens neurális háló (GRU)

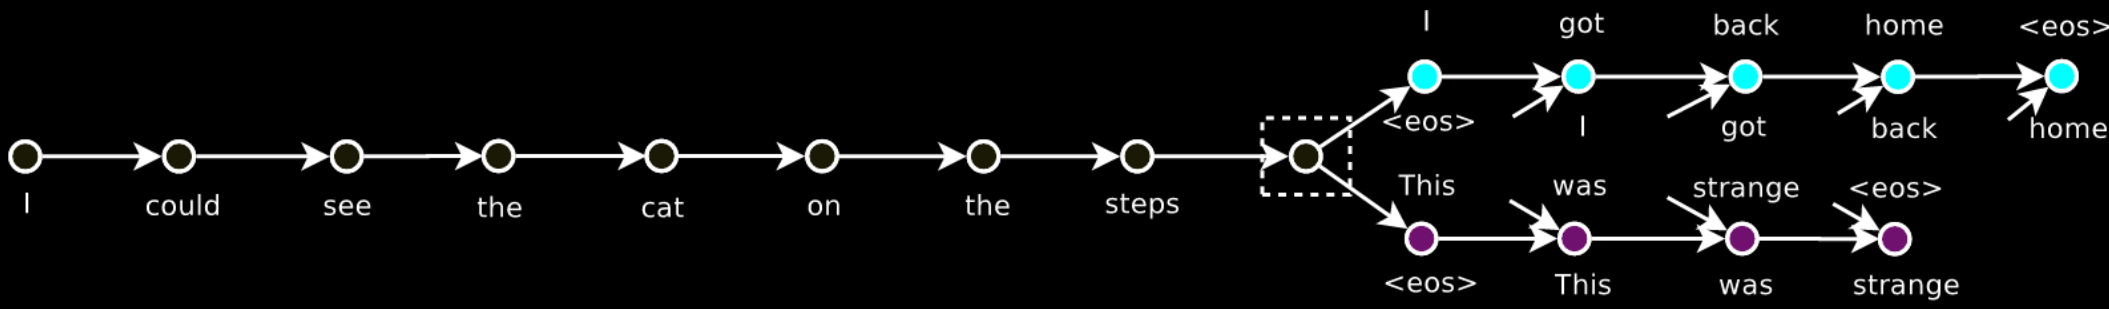

Query and nearest sentence
he ran his hand inside his coat , double-checking that the unopened letter was still there . he slipped his hand between his coat and his shirt , where the folded copies lay in a brown envelope .
im sure youll have a glamorous evening , she said , giving an exaggerated wink . im really glad you came to the party tonight , he said , turning to her .

Nyitott kérdések

- Következtetés, hétköznapi gondolkodás

A Corpus and Cloze Evaluation for Deeper Understanding of Commonsense Stories

Nasrin Mostafazadeh[1], Nathanael Chambers[2], Xiaodong He[3], Devi Parikh[4], Dhruv Batra[4], Lucy Vanderwende[3], Pushmeet Kohli[3], James Allen[1,5]

	Constant-choose-first	Frequency	N-gram-overlap	GenSim	Sentiment-Full	Sentiment-Last	Skip-thoughts	Narrative-Chains-AP	Narrative-Chains-Stories	DSSM	Human
Validation Set	0.514	0.506	0.477	0.545	0.489	0.514	0.536	0.472	0.510	0.604	1.0
Test Set	0.513	0.520	0.494	0.539	0.492	0.522	0.552	0.478	0.494	**0.585**	1.0