Distributed word embeddings

A szoftmax függvény

- Bináris osztályozás szigmoid függvénnyel $\sigma(z)=\frac{1}{1+\exp^{-z}}$
  - $z=w^T x$ mint normalizálatlan valószínűség
  - Alternatívan legyen $z_1=w_1^T x$ és $z_2=w_2^T x$ a pozitív és negatív osztályba tartozás normalizálatlan valószínűségei
  - $softmax(z)=\left[\frac{\exp^{z_1}}{\exp^{z_1}+\exp^{z_2}}, \frac{\exp^{z_2}}{\exp^{z_1}+\exp^{z_2}}\right]$
  - $z=z_1-z_2$ választással a logisztikus regresszió is ezt csinálja

Szoftmax példa

- A szoftmax függvény segítségével (-∞, ∞) intervallumból jövő értékekből eloszlást gyárthatunk
  - Osztályozást végző neurális hálók gyakori összetevője

[-2, 3, 0] → [0.14 20.09 1.00]

[-1, 4, 1] → [0.37 54.60 2.72]

[1, 2, 2.3] → [2.72 7.39 9.97]

Szoftmax példa

- A szoftmax függvény segítségével (-∞, ∞) intervallumból jövő értékekből eloszlást gyárthatunk
  - Osztályozást végző neurális hálók gyakori összetevője

[-2, 3, 0] → [0.14 20.09 1.00] → [0.006 0.946 0.048]

[-1, 4, 1] → [0.37 54.60 2.72] → [0.006 0.946 0.048]

[1, 2, 2.3] → [2.72 7.39 9.97] → [0.189 0.377 0.434]

word2vec (Mikolov et al., 2013)

- Algoritmuscsalád több (kritikus) hiperparaméterrel
  - Alapcélja: olyan prediktív modellt tanulni, ami képes minél pontosabban megbecsülni, hogy ha egy szövegrészből kitakarunk egy/több szót, akkor mi/mik volt/voltak az/azok
- Minden szóhoz rendeljünk egy kontextus és output reprezentációt (egy-egy N dimenziós vektort)
  - Predikcióinkat a kontextus és output vektorok pontszorzatain alkalmazott szoftmax függvénnyel hozzuk meg

Continuous bag of words (CBOW) vs. Skipgram

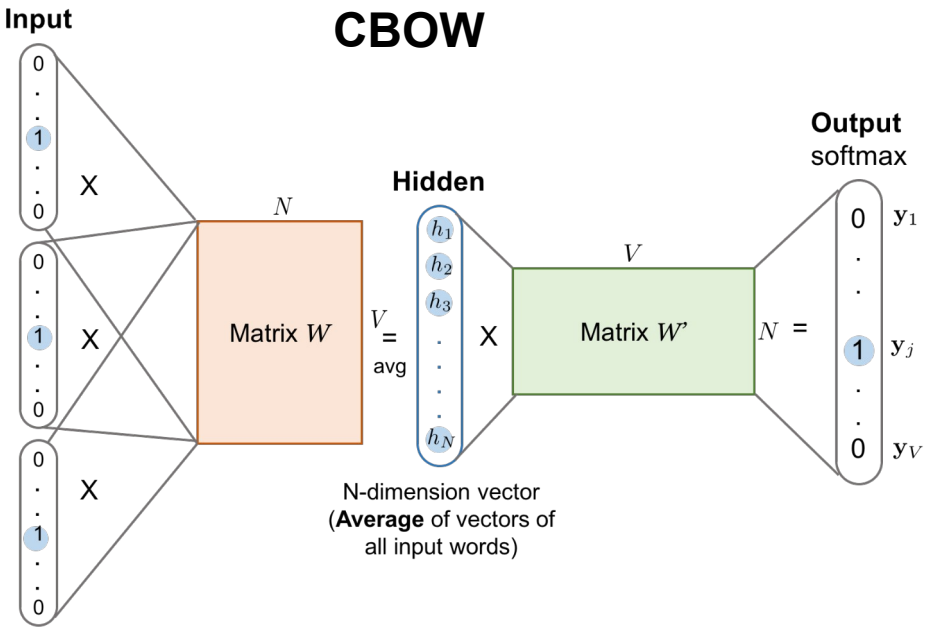

Képek forrása: lilianweng.github.io

Continuous bag of words (CBOW) vs. Skipgram

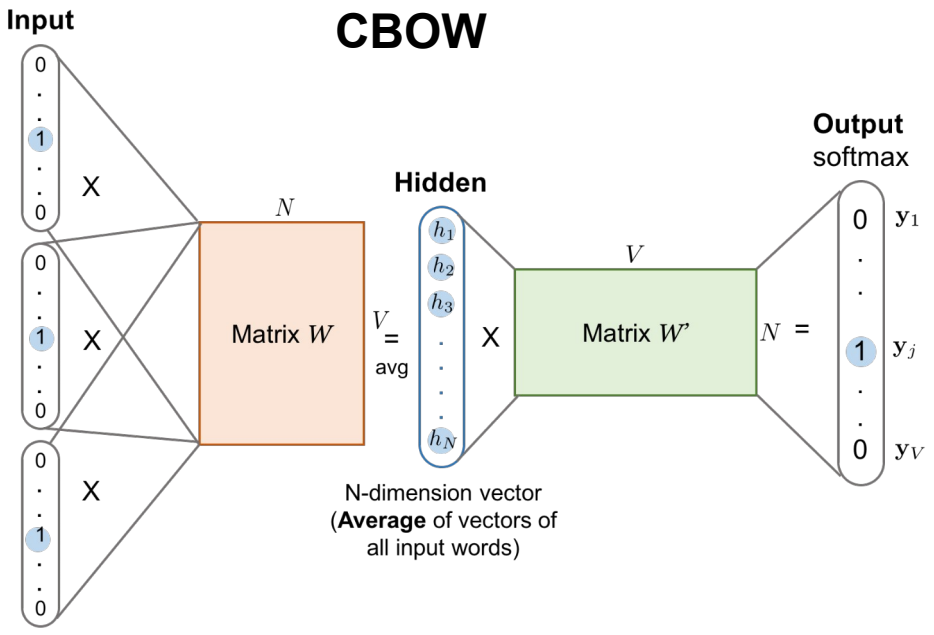

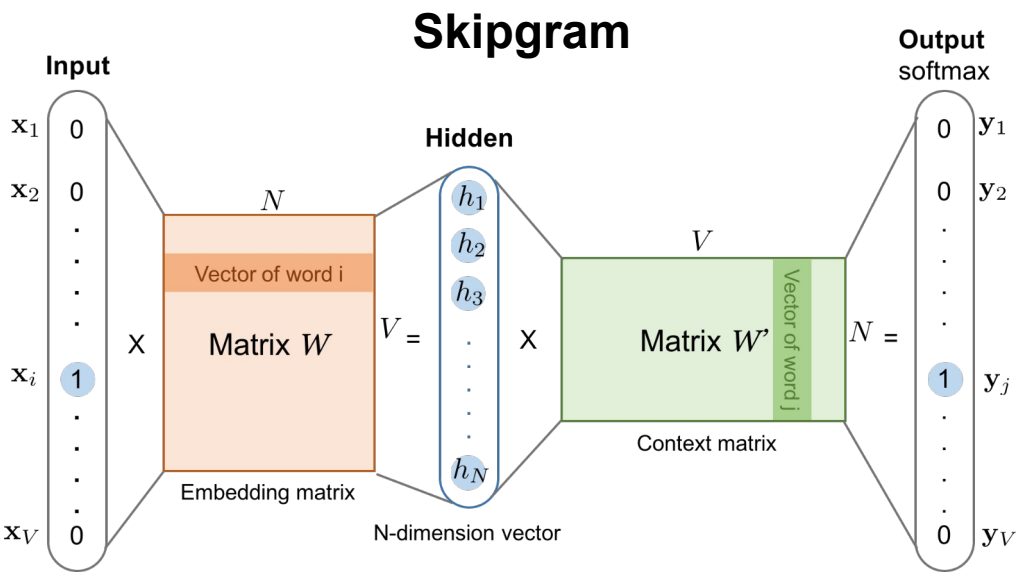

Képek forrása: lilianweng.github.io

A predikciós mechanizmus

- Egy-egy kontextusablak viszonyában regisztráljuk a predikció kapcsán jelentkező hibát, és frissítsük a szóreprezentációkat

$$p(o_i|c_j) = softmax(\mathbf{1}_j^T W W')$$

  - $\mathbf{1_j}$ = [0 0 0 … 0 0 1 0 0 … 0] alakú ún. one-hot vektor

j. pozíció

  - W és W’ paraméterek függetlenek egymástól (Miért?)
  - Kezdetben random értékekeket tartalmaznak, SGD-vel frissítjük őket a tanulás során

A frissítési szabály

- Szükségünk van a predikció hibájának gradiensére
  - A predikciós hiba az elvárt szó előrejelzésének negált log valószínűsége

$$\ell = -\log\left(p\left(o_i|c_j\right)\right) = -\log\frac{e^{w_j^T w_i^{'}}}{\sum_{k=1}^{|V|} e^{w_j^T w_k^{'}}} = ?$$

  - Mi lesz a hibatag gradiense? Hogy lehet értelmezni?
    - https://stats.stackexchange.com/questions/253244/gradients-for-skipgram-word2vec

Az elvi modell problémái

- A célfüggvény gradiensét nagyon költséges kiszámolni
  - Egyetlen frissítés alkalmával a teljes szótár (V) fölötti összegzést igényel
- A probléma javítható hierarchikus szoftmax vagy negatív mintavételezés alkalmazásával

Hierarchikus szoftmax

- A predikciós mechanizmust (W’) cseréljük le egy bináris fára
  - N csúcsú bináris fa várható magassága log(N) 👍
  - A bináris fa minden csúcsa egy-egy döntést hoz
  - Egy outputra vonatkozó predikció legyen a fában hozzá való eljutás során hozott döntések valószínűségeinek szorzata
- 1 db |V| kimenetelű multinomiális eloszlás helyett hozzunk *log(|V|)* bináris döntést

Hierarchikus szoftmax illusztrációja

- Minden csúcs egy-egy mini osztályozó
  - Balra vagy jobbra tovább?
- A hibát így propagáljuk vissza

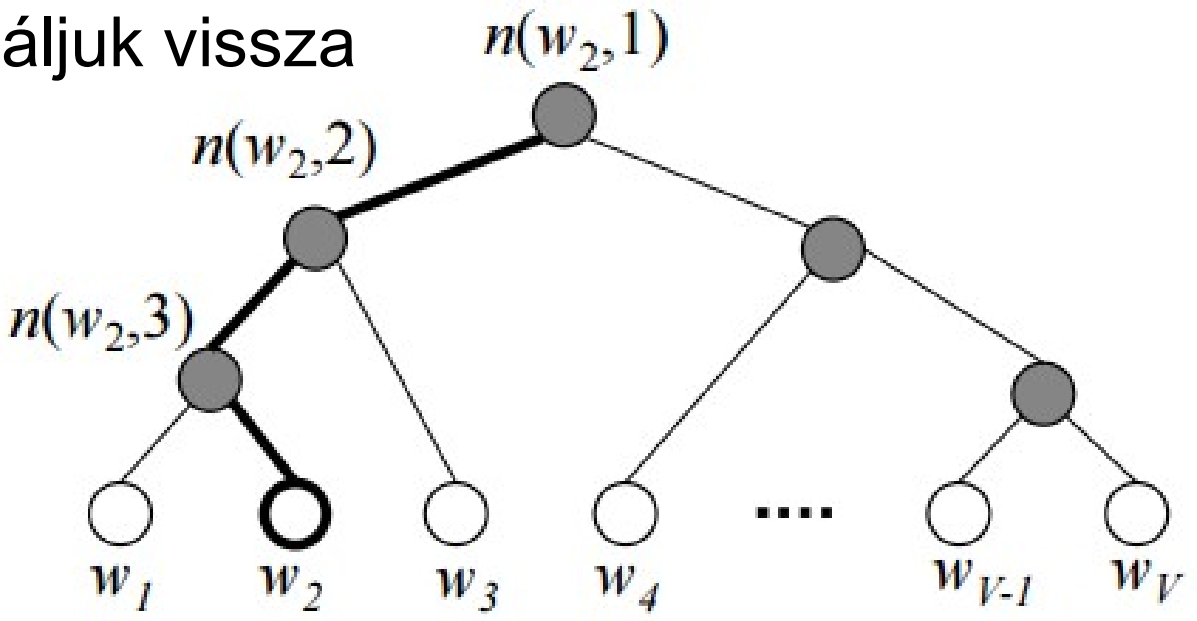

Negatív mintavételezés

- A teljes szótár feletti predikció helyett hozzunk *néhány* egyszerű bináris döntést (valid/invalid kontextus)
  - Bináris döntést hozni sokkal olcsóbb, mint egy |V| kimenetelest

$$\ell = -\log\left(p\left(Y=1|o_i, c_j\right)\right) - \sum_{k=1, o_k \sim Q}^{K} \log\left(p\left(Y=0|o_k, c_j\right)\right)$$

  - Q a szótár elemei feletti gyakorisági eloszlás

Negatív mintavételezés

- A teljes szótár feletti predikció helyett hozzunk *néhány* egyszerű bináris döntést (valid/invalid kontextus)
  - Bináris döntést hozni sokkal olcsóbb, mint egy |V| kimenetelest

$$\ell = -\log\left(p\left(Y=1|o_i,c_j\right)\right) - \sum_{k=1,o_k\sim Q}^{K} \log\left(p\left(Y=0|o_k,c_j\right)\right)$$

  - Q a szótár elemei feletti gyakorisági eloszlás
    - Q meghatározása során a szavak gyakoriságát emeljük egy 1-nél kisebb hatványra (pl. 0.75) → Miért jó ötlet ez?

További trükkök

- Adaptív ablakméret (távolabbi szomszédok alulsúlyozása)
- Gyakori szavak alulmintavételezése 1-sqrt(t/f(w)) valószínűséggel
  - t egy hiperparaméter (t≈1e-5)
  - f(w) a szó gyakorisága
- Gyakori mintázatok (pl. *New_York*) beazonosítása
  - Történhet pl. PPMI segítségével
- Stb, stb…

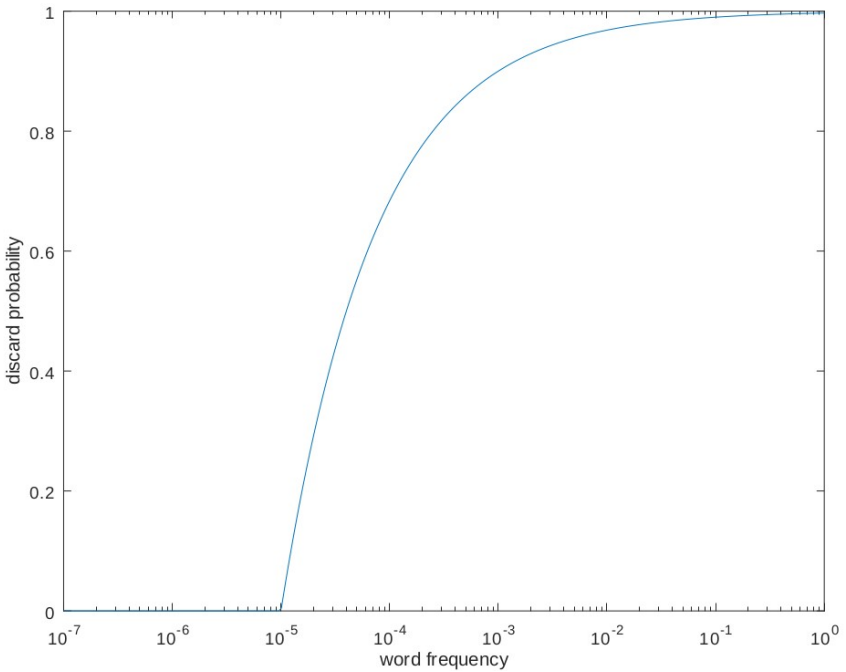

Egyéb megoldások – fasttext

- A szavak helyett gondolkozzunk szótöredékekben
  - Hasznos lehet morfológiailag változatos nyelvek esetében
  - Lényegében minden karakterlánchoz fogunk tudni reprezentációt adni a szótöredék–reprezentációkra alapozva
- A szavakhoz tartozó vektoros reprezentációra tekintsünk az azokat alkotó szótöredékek vektoros reprezentációinak összegeként
- Előtanított vektorok elérhetők 150+ nyelvre (fasttext.cc)

fasttext (Bojanowski et al., 2017)

- Lényegében a skipgram modell kiterjesztése input/output karakter n-gramokkal
- Az ábrán egy szópárra nézve, az azt alkotó töredékpárok reprezentációinak hasonlósága áll
  - Az x tengelyen mindkét esetben egy OOV szó áll

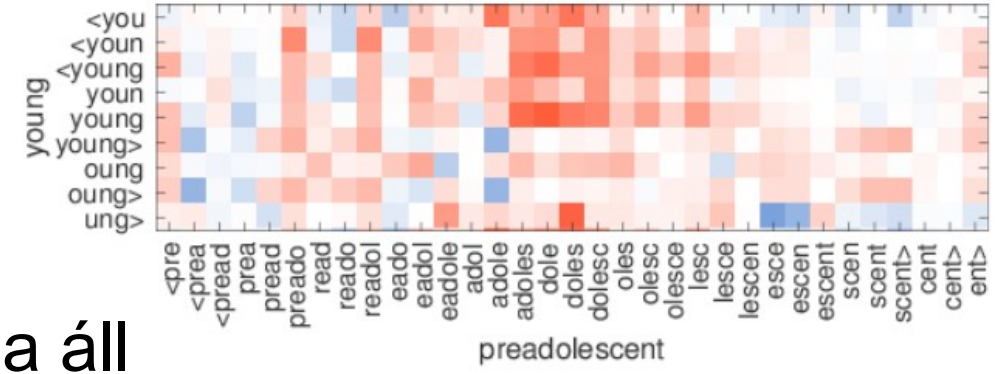

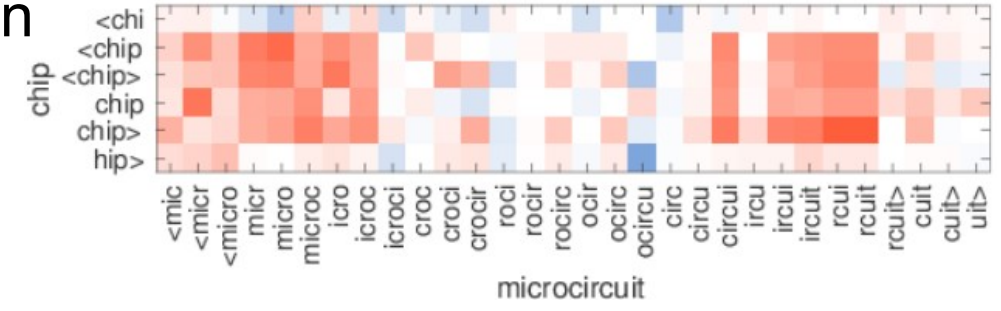

Retrofitting (Faruqui et al., 2015)

- Tanuljunk egy kezdeti szóreprezentációt q̂, majd ezt finomítsuk tudásbázisokra támaszkodva

$$\Psi(Q) = \sum_{i=1}^{n} \left[\alpha_i \|q_i - \hat{q}_i\|^2 + \sum_{(i,j) \in E} \beta_{ij} \|q_i - q_j\|^2 \right]$$

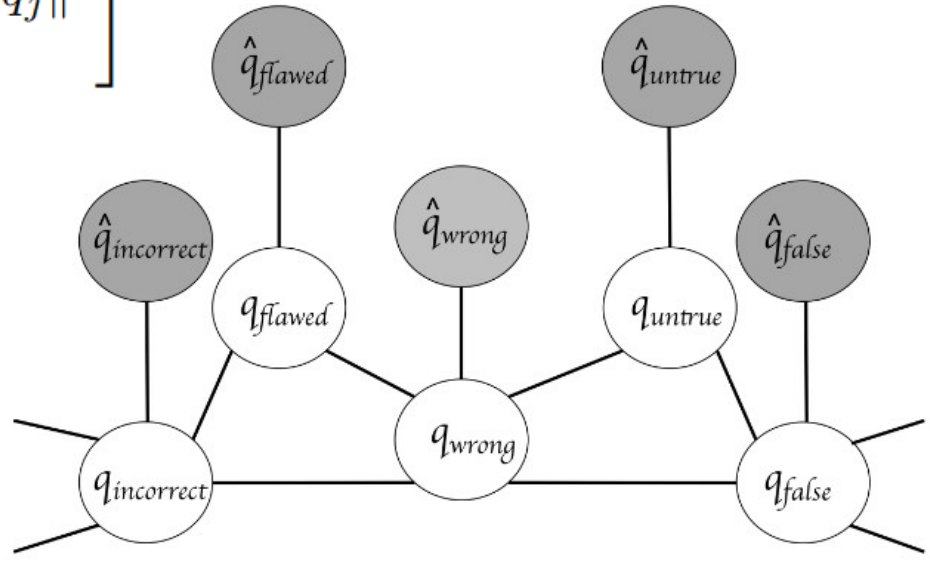

Retrofitting (Faruqui et al., 2015)

- Tanuljunk egy kezdeti szóreprezentációt q̂, majd ezt finomítsuk tudásbázisokra támaszkodva

$$\Psi(Q) = \sum_{i=1}^{n} \left[\alpha_i \|q_i - \hat{q}_i\|^2 + \sum_{(i,j) \in E} \beta_{ij} \|q_i - q_j\|^2 \right]$$

  - Azaz a tudásbázisban “összekötött” szavak viselkedjenek hasonlóan, miközben az eredetileg tanult reprezentációjuktól se térjenek el túlzottan

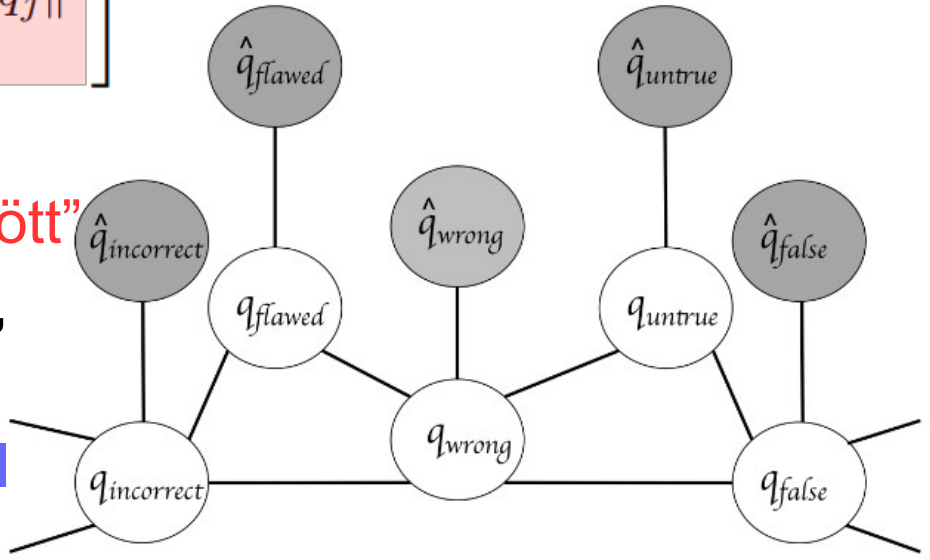

Explicit Retrofitting (Glavaš & Vulić, 2018)

- A Faruqui-féle retrofitting problémája, hogy csak a tudásbázisban található tudás integrálására képes
- Az explicit retrofitting megpróbálja a tudásbázisban tárolt tudást absztrahálni
  - Egy olyan neurális modellt tanul, ami utólagosan minden vektor specializálását el tudja végezni, nem csak a tudásbázisban lévőkét

Prior tudás integrálása (Song et al., 2017)

- A kontextusszó kilétén túl, valamilyen egyéb ismérv előrejelzésére is képessé akarjuk tenni a modellünket
  - A prior tudás jöhet tudásbázisból, de automatizmus által is előállhat (LDA=látens Dirichlet allokáció, egy topikmodell)

Prior tudás integrálása (Song et al., 2017)

- A kontextusszó kilétén túl, valamilyen egyéb ismérv előrejelzésére is képessé akarjuk tenni a modellünket
  - A prior tudás jöhet tudásbázisból, de automatizmus által is előállhat (LDA=látens Dirichlet allokáció, egy topikmodell)

$$\mathcal{L} = \frac{1}{|V|} \sum_{i=1}^{|V|} \log p(w_i, \psi(w_i) \mid \sum_{0<|j|\leq c} v_{i+j})$$

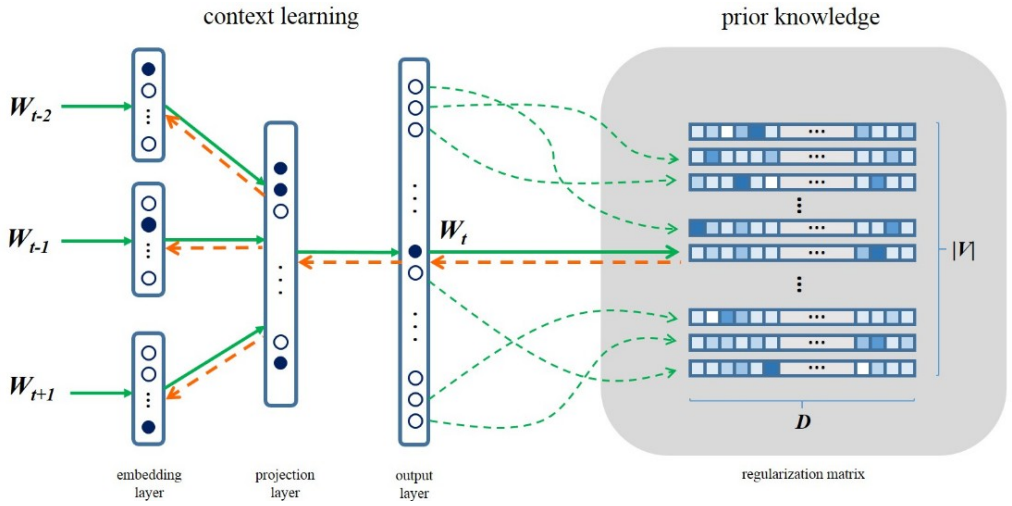

Glove (Pennington et al., 2014)

- Egyszerre globális és lokális
  - A korpusz globális statisztikáit próbálja a modell rekonstruálni
  - A paraméterek frissítése sztochasztikusan történik

$$J = \sum_{i,j}^{|V|} f(X_{ij})(w_i^T \tilde{w}_j + b_i + \tilde{b}_j - \log X_{ij})^2$$

Probability and Ratio	$k = solid$	$k = gas$	$k = water$	$k = fashion$
$P(k\|ice)$	1.9×10^{-4}	6.6×10^{-5}	3.0×10^{-3}	1.7×10^{-5}
$P(k\|steam)$	2.2×10^{-5}	7.8×10^{-4}	2.2×10^{-3}	1.8×10^{-5}
$P(k\|ice)/P(k\|steam)$	8.9	8.5×10^{-2}	1.36	0.96

Glove (Pennington et al., 2014)

- Egyszerre globális és lokális
  - A korpusz globális statisztikáit próbálja a modell rekonstruálni
  - A paraméterek frissítése sztochasztikusan történik

$$J = \sum_{i,j}^{|V|} f(X_{ij})\left(w_i^T \tilde{w}_j + b_i + \tilde{b}_j - \log X_{ij}\right)^2$$

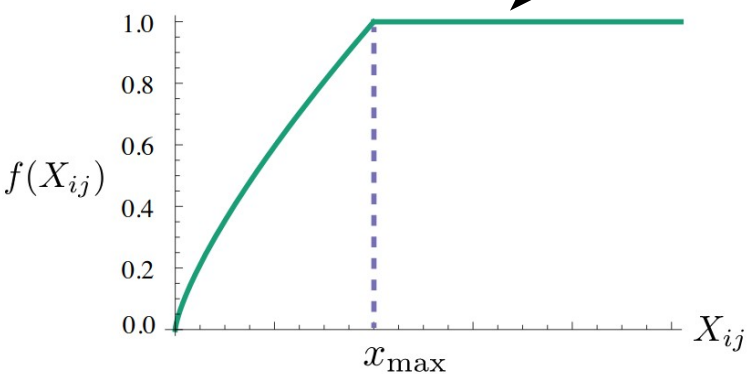

Globális együttelőfordulási gyakoriság

Szóreprezentációk kiértékelése

Szóhasonlóság

- Adott szópárok adatbázisa emberek által hozzárendelt hasonlósági értékekkel (similarity vs. relatedness)
- A szóreprezentációink alapján próbáljuk rekonstruálni az emberek által adott hasonlósági pontszámokat
  - Általában a szópárok vektorainak koszinusz hasonlóságának és az emberi hasonlóságok korrelációs együtthatóját nézzük

		emberi	automatikus
kutya	eb	9.9	9.1
kutya	hajó	1.1	1.7
...	...	...	...
ló	ménes	8	6.7

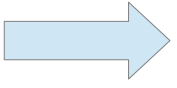

$\rho=0.62$

Lexikális következtetés

- (a,b) szópár vonatkozásában a reprezentációk alapján próbáljuk meg eldönteni, hogy a-ból következik-e b
  - Másképpen b hipernímája-e a-nak (általánosabb fogalom-e nála)
    - kutya → emlős
    - kutya ↛ hüllő
    - emlős ↛ kutya
  - (Levy et al., 2015) megmutatta, hogy a felügyelt módszerek hajlamosak a tanulni kívánt reláció helyett prototipikus hipernímákat tanulni csupán

Szóanalógiák

- A:B :: C:D alakú szópárok gyűjteménye
  - Milyen gyakran tudjuk eltalálni azt, hogy adott A, B és C-hez mi a legjobban passzoló D szó
    - A–B≈C–D, vagyis melyik D-nek a (C–A+B)-vel vett hasonlósága a maximális
    - (Levy & Goldberg, 2014): a (C–A+B)-t könnyen dominálni tudja egyetlen vektor, így keressük inkább azon D-t amire $\frac{\cos(D,C)*\cos(D,B)}{\cos(D,A)}$ maximális

Szóanalógiás adatbázisok

- Szintaktikus párok (walk:walked :: bake:baked)
- Szemantikus párok (Spain:Madrid :: France:Paris)
- Angolra pl. Google analogy test set vagy Better Analogy Test Set (BATS)
- Magyarra is létezik kiértékelő adatbázis http://corpus.nytud.hu/efnilex-vect/

Kiértékelésorientált utófeldolgozás (Artetxe et al., 2018)

- A szóreprezentációk változatos információkat tárolnak, amelyek a felszínre hozhatók
- Ha X a beágyazásmátrix, akkor $X X^T$ a szópárok (elsőfokú) hasonlóságát adja meg, $(X X^T)^n$ pedig az n-edfokút
  - $(X X^T)^n = X (X^T X)^{n-1} X$, ahol $X^T X$ felbontható $Q \Lambda Q^T$ alakban
  - A transzformált beágyazásmátrixunk legyen $X Q \Lambda^{1/2}$

QVEC (Tsvetkov et al., 2015)

- Korrelációalapú metrika, ami azt nézi, hogy a szóvektorok dimenziói mennyire feleltethetők meg dolgok valós életbeli tulajdonságainak
- X mátrix a szóbeágyazásokat, S pedig a szemantikus tudást tartalmazó mátrix

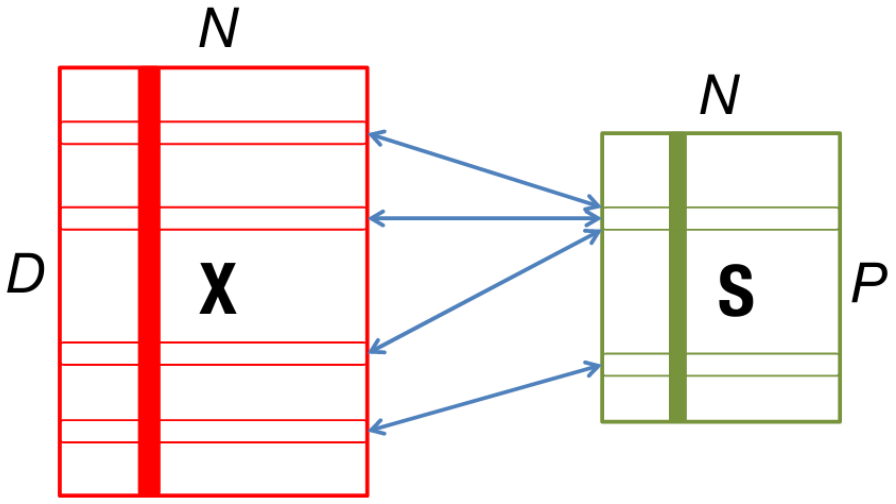

QVEC (Tsvetkov et al., 2015)

- Korrelációalapú metrika, ami azt nézi, hogy a szóvektorok dimenziói mennyire feleltethetők meg dolgok valós életbeli tulajdonságainak
- X mátrix a szóbeágyazásokat, S pedig a szemantikus tudást tartalmazó mátrix
  - S valamilyen tudásbázis alapján (pl. WordNet/SemCor) állítható elő

$$\text{QVEC} = \max_{\mathbf{A}|\sum_j a_{ij} \leq 1} \sum_{i=1}^{D} \sum_{j=1}^{P} r(\mathbf{x}_i, \mathbf{s}_j) \times a_{ij}$$

korreláció hozzárendelés

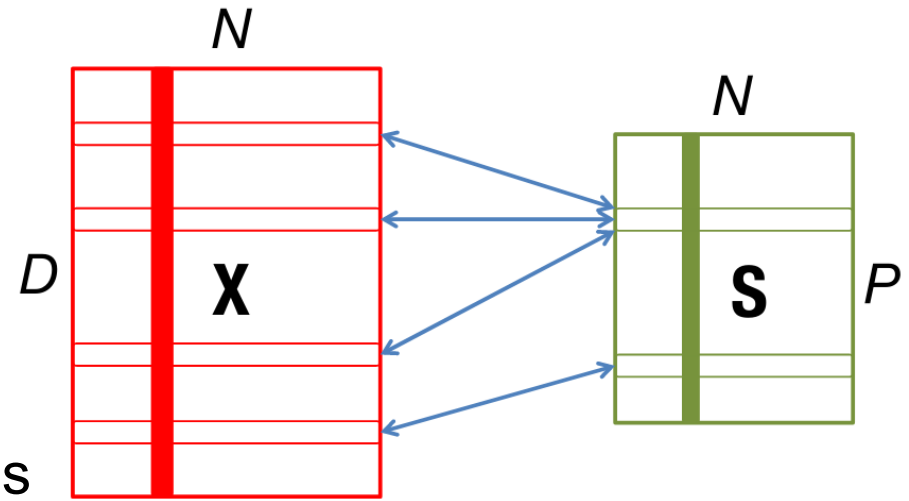

Alkalmazásban való kiértékelés

- Intrinzikus kiértékelésnél jóval költségesebb, viszont végső soron ez érdekel bennünket
- Sajnos az intrinzikus kiértékelés gyakran nem korrelál az alkalmazásbeli kiértékeléssel
- Kérdés, hogy a kapott eredmény mennyire köszönhető a szóreprezentációnak, illetve mennyiben az arra építő modellnek
- Intrinsic/extrinsic kiértékeléstől függetlenül, általában érdemes több benchmark adatbázison is mérjünk

Lehetséges külső kiértékelés: struktúratanulás

- Szekvenciaelemzés
  - Part-of-Speech tagging: mi az egyes szavak szófaja?
  - Named Entity Recognition: hol és milyen típusú tulajdonnév található a szövegben
    - A feltorlódó névelemeket el akarjuk tudni határolni egymástól
  - Chunkolás: sekély mondattani elemzés (főnévi/igei/melléknévi csoportok egymástól való elkülönítése)
  - ...
- Egyéb struktúrák tanulása, pl. konstituens vagy dependenciaelemzés

További alkalmazási lehetőségek

- Gépi fordítás
- Kérdésmegválaszolás
- Kivonatolás
- Dokumentumosztályozás